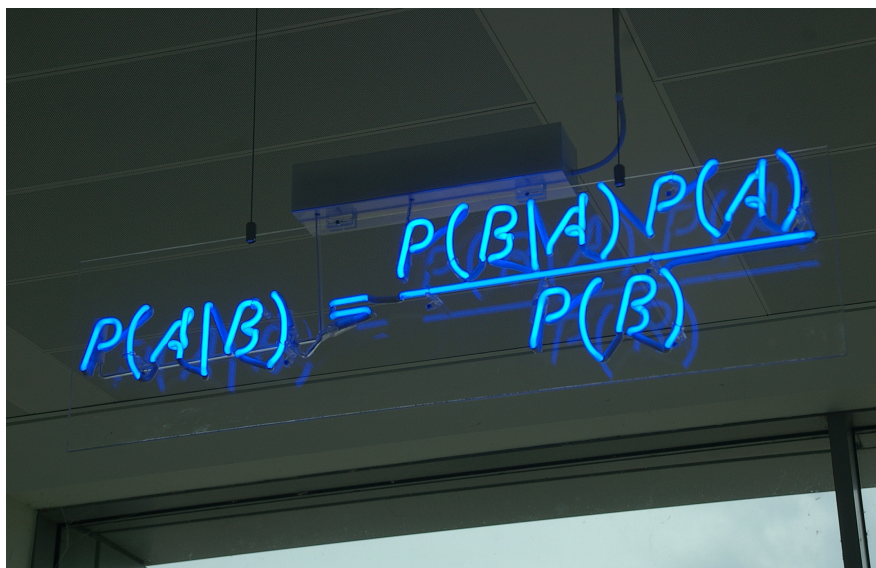



## Estatística bayesiana

- Os paradigmas bayesiano e frequentista;
- Distribuição *a priori* e *a posteriori*;
- Função de verossimilhança;

A photograph of a digital screen displaying the formula for Bayes' theorem in blue neon-style text. The formula is  $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$ . The screen is part of a presentation, with a dark background and some visible wiring above the display area.
$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$



# Permutabilidade

## Definição 9

**Permutabilidade.** Uma coleção finita de variáveis aleatórias  $X_1, X_2, \dots, X_n$  com densidade conjunta  $f$  é dita **permutável** se

$$f(x_1, x_2, \dots, x_n) = f(x_{\pi(1)}, x_{\pi(2)}, \dots, x_{\pi(n)}),$$

para qualquer permutação  $\pi = \{\pi(1), \pi(2), \dots, \pi(n)\}$  dos seus elementos. Uma coleção infinita é permutável se qualquer subconjunto finito é permutável.

- Note que uma amostra permutável não precisa ser independente;
- Note também que IID  $\implies$  permutável;
- A intuição é simples: simetria.

## Parâmetros como limites de variáveis aleatórias.

### Exemplo 1

**Ensaio Clínico (De Groot, exemplo 7.1.3).** Suponha que estamos interessados na taxa de recrudescência (“recaída”) de uma determinada doença entre pacientes tratados com uma droga. Seja  $X_i$  a variável aleatória que indica se o  $i$ -ésimo paciente recrudesceu ( $X_i = 1$ ) ou não ( $X_i = 0$ ). Seja  $P$  a proporção de indivíduos que recrudescem num grupo grande de pacientes. Se  $P$  é desconhecida, podemos modelar  $X_1, X_2, \dots$  como variáveis aleatórias Bernoulli IID com parâmetro  $p$  **condicional** a  $P = p$ . Em notação estatística:

$$X_1, X_2, \dots \mid P = p \sim \text{Bernoulli}(p).$$

**Assuma** que  $X_1, X_2, \dots$  é uma sequência permutável infinita. Agora chamemos de  $P_n$  a proporção de pacientes que recrudescem nos  $n$  primeiros pacientes. Podemos mostrar que o limite  $\lim_{n \rightarrow \infty} P_n = \lim_{n \rightarrow \infty} \sum_{i=1}^n X_i / n$  existe com probabilidade 1 e que pode ser visto como a proporção  $P$ .

## Paradigmas de inferência

No Exemplo 1 podemos encarar o problema de duas maneiras:

- A)  $P$  é uma variável aleatória e  $X_1, X_2, \dots$  são Bernoulli( $p$ ) **condicional** ao evento  $P = p$ ,  $p \in (0, 1)$ .
- B) Para uma constante fixa (e inobservável)  $p$ ,  $X_1, X_2, \dots$  tem distribuição Bernoulli com parâmetro  $p$  – isto é, indexada por  $p \in (0, 1)$ .

Uma diferença *sutil*, não é? A tradição estatística que entende parâmetros como variáveis aleatórias como em A) é chamada de **Estatística bayesiana**<sup>7</sup>. Já os que aderem à abordagem B) são chamados **frequentistas** – ou ortodoxos, como Jaynes gosta de chamá-los. Neste curso veremos conceitos e exemplos destas duas escolas de pensamento.

---

<sup>7</sup>Em homenagem ao reverendo inglês Thomas Bayes (1701 – 1761).

## Uma análise bayesiana

### Exemplo 2

**Duração de componentes eletrônicos (De Groot, exemplo 7.2.1).** Suponha que uma empresa esteja interessada em saber o quanto duram os produtos que ela produz. Se representamos os tempos de duração de  $n$  objetos como  $n$  variáveis aleatórias  $X_1, X_2, \dots, X_n$  IID com distribuição exponencial com parâmetro  $\theta$  de modo que


$$f(x_i | \theta) = \theta \exp(-\theta x_i), x_i > 0.$$

**Observação:**  $n / \sum_{i=1}^n x_i \xrightarrow{P} \theta$ .

Aqui,  $\theta$  é a taxa de falha dos componentes, e é um parâmetro de interesse.

Suponha que uma pessoa experiente na empresa diga que a taxa de falha é mais ou menos 0.5/ano. Como representamos esta informação?

## Uma análise bayesiana (cont.)



## A distribuição *a priori*

### Definição 10

**Distribuição *a priori*.** Se tratamos o parâmetro  $\theta$  como uma variável aleatória, então a distribuição *a priori*, que também chamaremos simplesmente de *priori*, é a distribuição que damos a  $\theta$  **antes** de observarmos as outras variáveis aleatórias de interesse. Em geral, vamos denotar a função de densidade/massa de probabilidade da *priori* por  $\xi(\theta)$ .

### Exemplos:

- Podemos dizer que a probabilidade de uma moeda cair cara,  $p$ , tem distribuição uniforme entre 0 e 1;
  - ◊ Ou que tem distribuição  $\text{Beta}(2, 2)$ ;
- A altura média dos jogadores de basquete do CR Flamengo tem distribuição normal com média  $\mu_0 = 200\text{cm}$  e variância  $\sigma_0^2 = 25\text{cm}^2$ ;
- A posição de Júpiter em relação ao Sol hoje tem coordenadas  $X, Y, Z$ , de modo que  $X \sim \text{Normal}(\mu_x, 1)$ ,  $Y \sim \text{Normal}(\mu_y, 1)$ ,  $Z \sim \text{Normal}(\mu_z, 1)$ .

## Distribuição *a posteriori*

### Definição 11

Considere o problema estatístico com parâmetro  $\theta$  e variáveis aleatórias observáveis  $X_1, X_2, \dots, X_n$ . A distribuição condicional de  $\theta$  dados os valores observados das variáveis aleatórias,  $\mathbf{x} := \{x_1, x_2, \dots, x_n\}$  é a **distribuição a posteriori** de  $\theta$ .

Denotamos por  $\xi(\theta | \mathbf{x})$  a f.d.p./f.m.p. condicional a  $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$ .

### Teorema 5

Considere a amostra aleatória  $X_1, X_2, \dots, X_n$  de uma distribuição com f.d.p./f.m.p.  $f(\mathbf{x} | \theta)$ . Se a distribuição a priori é  $\xi(\theta)$ , temos

$$\xi(\theta | \mathbf{x}) = \frac{\xi(\theta) \prod_{i=1}^n f(x_i | \theta)}{g_n(\mathbf{x})}, \quad \theta \in \Omega. \quad (4)$$

Chamamos  $g_n(\mathbf{x})$  de distribuição marginal de  $X_1, X_2, \dots, X_n$ .

**Prova:** Usar a premissa de amostra aleatória para escrever  $f(x_1, x_2, \dots, x_n | \theta)$ , escrever a distribuição conjunta de  $\theta$  e  $\mathbf{x}$  e computar  $g_n(\mathbf{x})$  usando a lei da probabilidade total.



## Distribuição *a posteriori*: exemplo

Continuando com o Exemplo 2, fica claro que

$$f(\mathbf{x} \mid \theta) = \prod_{i=1}^n f(x_i \mid \theta) = \theta^n \exp(-S\theta),$$

onde  $S = \sum_{i=1}^n x_n$ . Desta forma, temos

$$f(\mathbf{x} \mid \theta)\xi(\theta) = \theta^{n+1} \exp(-(S+2)\theta).$$

Para obter  $g_n(\mathbf{x})$ , computamos


$$g_n(\mathbf{x}) = \int_0^\infty t^{n+1} \exp(-(S+2)t) dt = \frac{\Gamma(n+2)}{(S+2)^{n+2}}.$$

Concluimos que

$$\xi(\theta \mid \mathbf{x}) = \frac{(S+2)^{n+2}}{\Gamma(n+2)} \theta^{n+1} \exp(-(S+2)\theta),$$

ou seja,  $\theta \mid \mathbf{x} \sim \text{Gama}(n+2, \sum_{i=1}^n x_n + 2)$ .

## Distribuição *a posteriori*: exemplo (cont.)



## A função de verossimilhança

Note que o denominador em (4) não depende do parâmetro,  $\theta$ . Deste modo, podemos escrever

$$\xi(\theta | \mathbf{x}) \propto f(\mathbf{x} | \theta)\xi(\theta),$$

querendo dizer que os dois lados de  $\propto$  são iguais a não ser talvez por uma constante que independe de  $\theta$ . Por vezes podemos escrever também  $\xi(\theta | \mathbf{x}) \propto_{\theta} f(\mathbf{x} | \theta)\xi(\theta)$ .


### Definição 12

**Função de verossimilhança.** Quando encaramos a f.d.p./f.m.p.  $f(x_1, x_2, \dots, x_n | \theta)$  como uma função do parâmetro  $\theta$ , chamamos esta função de **função de verossimilhança**, e podemos denotá-la como  $L(\theta; \mathbf{x})$  ou, quando a notação não criar ambiguidade, simplesmente  $L(\theta)$ .

## Aprendizado bayesiano sequencial

Ainda sobre o Exemplo 2, considere a primeira observação  $x_1$  e a distribuição *a posteriori* baseada apenas nesta observação:  $\xi_1(\theta | x_1) \propto f(x_1 | \theta)\xi(\theta)$ . Se assumirmos que  $X_1, X_2, \dots, X_n$  são condicionalmente independentes dado  $\theta$ , podemos escrever

$$\xi(\theta | x_1, x_2) \propto f(x_1, x_2 | \theta)\xi(\theta) = f(x_1 | \theta)f(x_2 | \theta)\xi(\theta) = f(x_2 | \theta)\xi_1(\theta | x_1).$$



## Predição

Dentro do paradigma bayesiano, a predição de novos valores da(s) variável(is) aleatória(s) é feita a partir da distribuição *a posteriori*,

$$p(x_{n+1} \mid x_1, x_2, \dots, x_n) = \int_{\Omega} f(x_{n+1} \mid \theta) \xi(\theta \mid x_1, x_2, \dots, x_n) d\theta. \quad (5)$$

Chamamos a distribuição condicional em (5) de **distribuição preditiva *a posteriori***. Em contraste, temos a **distribuição preditiva *a priori***:

$$p(x_{n+1}) = \int_{\Omega} f(x_{n+1} \mid \theta) \xi(\theta) d\theta, \quad (6)$$

que é útil na aplicação de modelos bayesianos na prática, mas não será explorada aqui.


## O que aprendemos?

- 💡 Bayesianismo X frequentismo;  
“Parâmetros como variáveis aleatórias ou constantes fixas e não-observáveis.”
- ⌚ Distribuição *a priori*,  $\xi(\theta)$ ;  
“Nosso grau de crença antes de observamos dados.”
- 📌 Função de verossimilhança,  $L(\theta) \propto f(\mathbf{x} | \theta)$ ;  
“Codifica (toda) a informação sobre o modelo contida nos dados.”
- ⌚ Distribuição *a posteriori*,  $\xi(\theta | \mathbf{x}) \propto L(\theta)\xi(\theta)$ ;  
“Nossa crença atualizada a partir da informação contida em  $L(\theta)$ .”

## Leitura recomendada

---

 De Groot seção 7.2;

 \* Capítulo 1 de Schervish, M. J. (2012). Theory of statistics. Springer Science & Business Media.