

Tópicos da aula

- Estimador de máxima verossimilhança (EMV);
 - ◇ Existência e unicidade;
 - ◇ Invariância do EMV;
 - ◇ Consistência do EMV;
- Limitações;

Estimador de máxima verossimilhança (EMV)

Definição 21 (Estimador de máxima verossimilhança)

Para cada possível vetor (de observações) \mathbf{x} , seja $\delta(\mathbf{x}) \in \Omega$ um valor de $\theta \in \Omega$ de modo que a função de verossimilhança, $L(\theta) \propto f(\mathbf{x} | \theta)$, atinge o máximo.

Dizemos que $\hat{\theta} = \delta(\mathbf{X})$ é o **estimador de máxima verossimilhança** de θ (Fisher, 1922)⁸. Quando observamos $\mathbf{X} = \mathbf{x}$, dizemos que $\delta(\mathbf{x})$ é uma estimativa de θ .

Dito de outra forma,

$$\max_{\theta \in \Omega} f(\mathbf{X} | \theta) = f(\mathbf{X} | \hat{\theta}).$$

⁸Ronald Aylmer Fisher (1890-1962), biólogo e estatístico inglês. Para a história do desenvolvimento do EMV, ver [Aldrich \(1997\)](#).

Mudando de paradigma

Na Definição 21, vemos θ com um número real que indexa a distribuição de probabilidade conjunta dos dados.

- Poderíamos trocar⁹ $f(x | \theta)$ por $f(x; \theta)$;
- Com o EMV, procuramos um valor de θ de modo que a probabilidade de observarmos $\mathbf{X} = \mathbf{x}$ seja máxima;
- Isso não nos diz nada sobre o quão provável $\hat{\theta}$ é;
- θ não é uma quantidade aleatória, portanto não admite afirmações probabilísticas.

⁹Mas não vamos, pois a notação fica clara em quase todos os contextos.

Exemplos

- Exponencial;
- Bernoulli;
- Normal;
 - ◇ μ desconhecida, σ^2 conhecida;
 - ◇ μ conhecida, σ^2 desconhecida;
 - ◇ μ e σ^2 ambas desconhecidas.

EMVs

- Exponencial: $\hat{\theta} = \bar{X}_n$;
- Bernoulli $\hat{\theta} = \bar{X}_n$;
- Normal;
 - ◊ $\hat{\mu} = \bar{X}_n$;
 - ◊ $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$;
 - ◊ $\hat{\theta} = \left\{ \hat{\mu} = \bar{X}_n, \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \right\}$.

EMV para uma distribuição uniforme

Exemplo 5 (EMV para uniforme)

Suponha que X_1, X_2, \dots, X_n perfazem uma amostra aleatória de uma distribuição uniforme no intervalo $[0, \theta]$, $\theta \in \mathbb{R}, \theta > 0$. Considere a f.d.p.

$$f(x | \theta) = \begin{cases} \frac{1}{\theta}, & 0 \leq x \leq \theta, \\ 0, & \text{caso contrário.} \end{cases} \quad (12)$$

A f.d.p. conjunta é

$$f_n(\mathbf{x} | \theta) = \begin{cases} \theta^{-n}, & 0 \leq x_i \leq \theta \ (i = 1, 2, \dots, n), \\ 0, & \text{caso contrário,} \end{cases} \quad (13)$$

e o EMV é $\hat{\theta} = \max(x_1, x_2, \dots, x_n)$.

Existência do EMV

Observação 5

A existência do EMV pode depender de detalhes irrelevantes acerca do espaço de parâmetros, Ω .

Exemplo 6 (Não existência do EMV)

Considere o Exemplo 5, mas agora com uma f.d.p. um pouco diferente:

$$f(x | \theta) = \begin{cases} \frac{1}{\theta}, & 0 < x < \theta, \\ 0, & \text{caso contrário.} \end{cases} \quad (14)$$

É fácil mostrar que, nesse caso, o EMV não existe.

Unicidade do EMV

Observação 6 (Unicidade do EMV)

Mesmo quando existe, o EMV nem sempre é único.

Exemplo 7 (EMV para uma uniforme num intervalo de tamanho 1)

Suponha que X_1, X_2, \dots, X_n perfazem amostra aleatória de uma distribuição uniforme no intervalo $[\theta, \theta + 1]$. A densidade conjunta é

$$f_n(\mathbf{x} \mid \theta) = \begin{cases} 1, & \theta \leq x_i \leq \theta + 1, (i = 1, 2, \dots, n), \\ 0, & \text{caso contrário.} \end{cases} \quad (15)$$

Defina $m := \min(x_1, x_2, \dots, x_n)$ e $M := \max(x_1, x_2, \dots, x_n)$. Podemos reescrever (15) como

$$f_n(\mathbf{x} \mid \theta) = \begin{cases} 1, & M - 1 \leq \theta \leq m, (i = 1, 2, \dots, n), \\ 0, & \text{caso contrário.} \end{cases} \quad (16)$$

Conclusão: $\hat{\theta}$ é qualquer valor no intervalo $[M - 1, m]$.

Invariância do EMV

Suponha que estamos interessados em uma transformação do parâmetro θ , $\phi(\theta)$. Por exemplo, se X_1, X_2, \dots, X_n são Bernoulli com parâmetro p , podemos estar interessados na *chance* $\omega = \phi(p) = p/(1 - p)$.

Teorema 11 (Invariância do EMV)

Considere uma função $\phi : \Omega \rightarrow \mathbb{R}$. Se $\hat{\theta}$ é um EMV para θ , então $\phi(\hat{\theta})$ é um EMV para $\omega = \phi(\theta)$.

Prova: Defina a *verossimilhança induzida*:

$$L^*(\omega) := \sup_{\{\theta: \phi(\theta)=\omega\}} L(\theta),$$

e note que o supremo desta função sobre Ω é precisamente o EMV. Ver Casella & Berger, Teorema 7.2.10 (pág. 320) ou De Groot, Teorema 7.6.2 (pág 427).

Exemplo: O EMV para o quadrado da média de uma normal, μ^2 , é \bar{X}_n^2 .

Consistência do EMV

Sob condições de regularidade, o EMV é consistente, isto é $\hat{\theta}_{EMV} \rightarrow \theta$.

Teorema 12 (Consistência do EMV)

Defina $l(\theta) := \log f_n(\mathbf{x} \mid \theta)$ e assumamos que $X_1, X_2, \dots, X_n \sim f(\theta_0)$, isto é, que θ_0 é o valor verdadeiro do parâmetro. Denote $E_{\theta_0}[g] := \int_{\Omega} g(\mathbf{x}, \theta) f(\mathbf{x} \mid \theta_0) d\mathbf{x}$. Suponha que

- $f(x_i \mid \theta)$ tem o mesmo suporte;
- θ_0 é ponto interior de Ω ;
- $l(\theta)$ é diferenciável;
- $\hat{\theta}_{EMV}$ é a única solução de $l'(\theta) = 0$.

Então,

$$\hat{\theta}_{EMV} \rightarrow \theta.$$

Prova: (rascunho) mostrar que, para todo $\theta \in \Omega$,




$$\frac{1}{n} \sum_{i=1}^n \log f(X_i \mid \theta) \rightarrow E_{\theta_0} [\log f(\mathbf{X} \mid \theta)],$$

e aplicar a desigualdade de Jensen.

O que aprendemos?

- 💡 Estimador de máxima verossimilhança (EMV);
“Encontrar o valor do parâmetro que maximiza a probabilidade observar os dados obtidos”
- 💡 Invariância ;
“O EMV é invariante a transformações dos parâmetros; se $\hat{\theta}$ é o EMV para θ , $\psi(\hat{\theta})$ é o EMV para $\psi(\theta)$ ”
- 💡 Consistência;
“Sob condições brandas de regularidade, o EMV converge para valor verdadeiro à medida que $n \rightarrow \infty$ ”
- 💡 Limitações;
“O EMV não existe necessariamente, e, mesmo quando existe, não precisa ser único”

Leitura recomendada

-  De Groot seções 7.5 e 7.6;
-  * Casella & Berger, seção 7.2.2.
-  * Schervish (1995), seção 5.1.3.

- **Exercícios recomendados**

-  De Groot,

- Seção 7.5: exercícios 1, 4, 9 e 10;

- Seção 7.6: exercícios 3, 5 e 11.